

TP2 - éléments de correction

automne 2021

Exercice 1

a)


On souhaite construire un histogramme, donc un diagramme qui rend compte de la densité de la distribution des données. La densité d_C associée à une classe $C = [a; b[$ est la proportion des individus $\pi_C = \frac{n_C}{N}$ appartenant à cette classe, divisée par l'amplitude de cette classe. On a donc :

$$d_C = \frac{n_C}{N} \frac{1}{b-a}.$$

Une façon de voir les choses est la suivante. On construit le diagramme en bâtons de façon à ce que la *surface* de chaque bâton soit égale à la proportion π_C des individus appartenant à la classe correspondante C . La surface du bâton associé à la classe C est $hauteur \times largeur = d_C \times (b-a) = \frac{n_C}{N} \frac{1}{b-a} (b-a) = \frac{n_C}{N} = \pi_C$.

```
superficie <- c("[0;5[","[5;10[","[10;20[","[20;50[","[50;100[")
bornes <- c(0, 5, 10, 20, 50, 100)
effectif <- c(5, 24, 38, 26, 7)
amplitudes <- diff(bornes)
centres <- bornes[-6] + amplitudes/2
hauteurs = effectif/sum(effectif)/amplitudes
```

```
barplot(height = hauteurs,
        width = amplitudes,
        names.arg = superficie,
        las = 2,
        col = 'orange')
```



b)

Les effectifs et fréquences cumulés croissants et décroissants sont faciles à calculer.

```
ecc <- cumsum(effectif)
ecd <- rev(cumsum(rev(effectif)))
fcc <- cumsum(effectif)/sum(effectif)
fcd <- rev(cumsum(rev(effectif)))/sum(effectif)
```

c)

Le mode est le centre de la classe de plus forte densité (la classe dont le bâton est le plus haut).

```
centres[which(rank(hauteurs)==5)]
```

```
## [1] 7.5
```

d)

On reproduit artificiellement des données correspondant à la situation décrite dans l'énoncé en répétant les valeurs des centres le nombre de fois que cette classe est observée.

```
donnees <- rep(centres, effectif)
mean(donnees)
```

```
## [1] 21.975
```

```
var(donnees)
```

```
## [1] 331.9817
```

e)

Ce calcul est élémentaire, et peut se réaliser de plusieurs façons.

```
median(donnees)
```

```
## [1] 15
```

```
quantile(donnees, 0.5)
```

```
## 50%
```

```
## 15
```

Exercice 2


On commence par reporter les données de l'énoncé dans R.

```
vers <- 0:7  
prelevements <- c(13, 27, 28, 19, 8, 3, 1, 1)
```

a)

L'unité statistique est le prélèvement. Une *observation* dans ce contexte est un échantillon de sable, dans lequel on compte le nombre de vers. L'unique variable ici est la variable quantitative discrète qu'est le nombre de vers. À chaque unité statistique (prélèvement), on associe la valeur de la variable "nombre de vers".

```
barplot(height = prelevements/sum(prelevements),  
        names.arg = vers,  
        col = 'orange')
```



b)

C'est facile.

```
fcc <- cumsum(prelevements)/sum(prelevements)
fcd <- rev(cumsum(rev(prelevements)))/sum(prelevements)
```

c)

Comme dans l'exercice 1, on reproduit les données, cette fois-ci de façon exacte.

```
donnees <- rep(vers, prelevements)
mean(donnees)
```

```
## [1] 2
```

```
var(donnees)
```

```
## [1] 2
```

d)

Ces calculs sont faciles. On utilise une petite astuce pour retrouver le mode.

```
vers[rank(prelevements)==8]
```

```
## [1] 2
```

```
quantile(donnees, 0.25)
```


```
## 25%  
## 1
```

Exercice 3

a)

L'unité statistique est le prélèvement de sang. La variable est le décompte des hématies dans ce prélèvement ; c'est une variable quantitative discrète à valeurs entières.

```
i <- 0:10  
ni <- as.integer(unlist(strsplit("12 42 91 111 100 66 46 21 8 2 1", split = " ")))  
N <- 500  
barplot(height = ni/N,  
        names.arg = i,  
        col = 'orange')
```



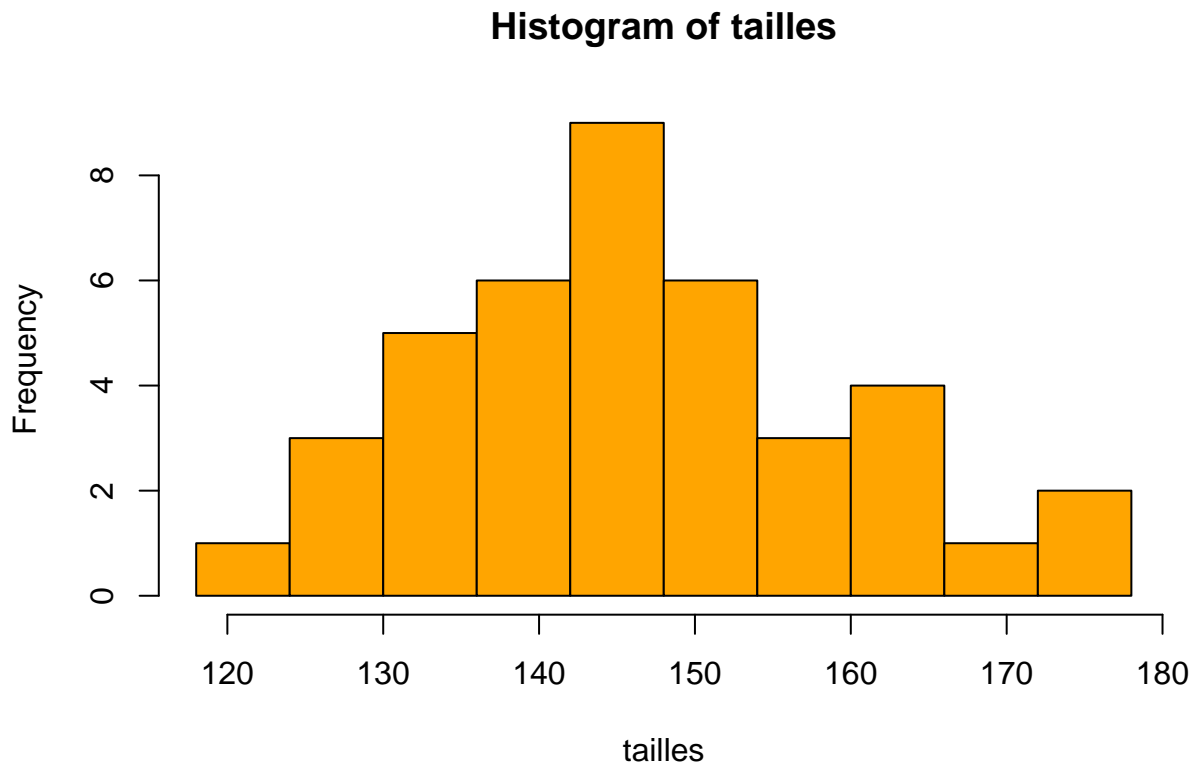
b)

```
freq <- ni/N  
fcc <- cumsum(freq)  
fcd <- rev(cumsum(rev(freq)))  
tab <- as.table(rbind(freq, fcc, fcd))  
colnames(tab) <- i  
tab
```

```
##      0      1      2      3      4      5      6      7      8      9     10
```



```
h <- hist(tailles,
  breaks = seq(118, 178, 6),
  col = 'orange')
```



```
inter <- function(vec) {
  paste(c("[", vec[1], ";", vec[2], "["), collapse = "")
}
```


```
bornes <- matrix(rep(seq(118, 178, 6), c(1,rep(2,9),1)),
  ncol = 2,
  byrow = T)
classes <- apply(bornes, 1, inter)
tab <- as.table(rbind(h$counts))
colnames(tab) <- classes
rownames(tab) <- "effectif"
tab
```

```
##          [118;124[ [124;130[ [130;136[ [136;142[ [142;148[ [148;154[ [154;160[
## effectif          1          3          5          6          9          6          3
##          [160;166[ [166;172[ [172;178[
## effectif          4          1          2
```

```
centres <- apply(bornes, 1, mean)
mu <- sum(centres*h$counts)/length(tailles)
sig2 <- sum(h$counts*(centres-mu)**2)/(length(tailles)-1)
```

c)

```
h <- hist(tailles,  
  breaks = c(118, 132, 144, 152, 164, 178),  
  col = 'violet')
```



```
bornes <- matrix(rep(c(118, 132, 144, 152, 164, 178), c(1,rep(2,4),1)),  
  ncol = 2,  
  byrow = T)  
classes <- apply(bornes, 1, inter)  
tab <- as.table(rbind(h$counts))  
colnames(tab) <- classes  
rownames(tab) <- "effectif"  
tab
```

```
##          [118;132[ [132;144[ [144;152[ [152;164[ [164;178[  
## effectif          5         12         11          8          4
```

```
centres <- apply(bornes, 1, mean)  
mu <- sum(centres*h$counts)/40  
sig2 <- sum(h$counts*(centres-mu)**2)/39  
mu
```

```
## [1] 146.425
```



```
sig2
```

```
## [1] 170.8147
```